


Especialización en ciencia y analítica de datos

# Sistemas de aprendizaje automático

*Aprendizaje de datos históricos*

---

JAVIER ANDRÉS CAUSIL MARTÍNEZ









# Índice general



# Índice de figuras





# Índice de tablas



# Prefacio

Este libro busca ser un compendio de práctica y teoría para entender el aprendizaje automático.



## PARTE I

# Algoritmos y Modelos en Machine Learning



La minería de datos o data mining, hace referencia a todas las técnicas que permiten extraer conocimiento de un conjunto de datos para descubrir, si es que existen, relaciones, modelos, regularidades o patrones que subyacen en un conjunto de datos y que, a priori, desconocemos.




Figura 1: \*

**Figura 1.3.** Cadena de valor del dato.

Abarca técnicas de limpieza, transformación y análisis de datos con el fin de descubrir patrones y características específicas. Mientras que el aprendizaje automático engloba los algoritmos y modelos para que las máquinas aprendan y resuelvan tareas automáticamente.

## 0.1 ¿Qué áreas relaciona?

Cómo es el proceso de analizar grandes volúmenes de información (*Big Data*) para descubrir patrones ocultos, correlaciones, tendencias y anomalías que no son evidentes a simple vista.

Es un campo interdisciplinario que se encuentra justo en la intersección de tres grandes áreas:

- **Estadística:** Para entender la distribución y la probabilidad de los datos.
- **Machine Learning:** Para aplicar los algoritmos que automatizan la búsqueda de patrones.
- **Sistemas de Bases de Datos:** Para almacenar y gestionar eficientemente la información masiva.

## 0.2 ¿Cuál es su objetivo principal?

El objetivo fundamental de la minería de datos es **extraer conocimiento útil a partir de datos crudos y transformarlo en información accionable**.

En términos prácticos, busca responder preguntas complejas para tomar decisiones estratégicas. Por ejemplo:

- **Predecir el futuro:** ¿Qué clientes tienen más probabilidad de cancelar su suscripción el próximo mes?
- **Clasificar:** ¿Esta transacción bancaria es legítima o es un fraude?
- **Agrupar (Clustering):** ¿Cómo podemos dividir a nuestros compradores en segmentos con gustos similares para lanzar campañas personalizadas?

## 0.3 Organización: El Proceso CRISP-DM

Para que la minería de datos se ejecute de forma estructurada, la industria utiliza metodologías estándar. La más famosa y utilizada a nivel mundial es **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*). Este marco de trabajo organiza todo proyecto en 6 fases cíclicas:

1. **Comprensión del Negocio (Business Understanding):** Antes de procesar datos, se debe entender el problema a resolver. Se definen los objetivos comerciales y los criterios de éxito del proyecto.
2. **Comprensión de los Datos (Data Understanding):** Se recolectan los datos iniciales y se realiza una exploración preliminar. Se identifican problemas de calidad (datos faltantes, errores) y se descubren pistas iniciales.
3. **Preparación de los Datos (Data Preparation):** Suele ser la fase que más tiempo consume (70 % - 80 % del proyecto). Involucra limpiar bases de datos, transformar variables, unir tablas y formatear la información para los algoritmos.
4. **Modelado (Modeling):** Se seleccionan y aplican diversas técnicas de Machine Learning (como las vistas anteriormente). Se calibran los parámetros (hiperparámetros) para encontrar el modelo con mejor rendimiento.
5. **Evaluación (Evaluation):** Se analiza el modelo rigurosamente. No solo se verifica su precisión matemática, sino que se valida si realmente cumple con el objetivo de negocio planteado en la primera fase.
6. **Despliegue (Deployment):** El modelo se lleva al entorno real. Puede implementarse como un reporte técnico, un panel interactivo (*dashboard*) o integrarse como un sistema automatizado.



## PARTE II

# Conceptos Fundamentales



## PARTE III

# Estadística

